

Chaînes de Markov, méthodes Monte-Carlo par Chaînes de Markov

Quelques éléments de théorie et application à la
simulation du modèle d'Ising

Rapport de stage de Licence

Thèmes: Probabilités, Méthodes Numériques, Physique du solide

VELCIN BASTIEN

Table des matières

Avant-propos	3
1 Chaînes de Markov	4
1.1 Définition et premières propriétés	4
1.2 Classification des états	6
1.3 Théorème ergodique et convergence ergodique	7
2 Méthodes de Monte Carlo par Chaînes de Markov	8
3 Temps de mélange et phénomène de Cutoff	9
4 Application : Le modèle d'Ising	11
4.1 Ferromagnétisme d'un matériau	11
4.2 Modèle d'Ising : quelques généralités	11
4.3 Modèle d'Ising en deux dimensions : étude et simulations	12
4.3.1 Construction théorique	12
4.3.2 Quelques exemples tirés de la simulation	14
4.4 Phénomène de Cutoff pour le modèle d'Ising	15
Appendices	17
A Simulation du modèle d'Ising en Python	17
Références	20

Avant-propos

Dans le cadre du stage obligatoire de ma troisième année de Licence de Mathématiques à l'Université de Lorraine, j'ai eu l'opportunité d'effectuer un stage de recherche au sein du laboratoire de mathématiques de l'Université de Lorraine : l'Institut Élie Cartan de Lorraine (IECL). Initié en novembre, j'ai eu l'occasion durant ce stage d'approfondir mes connaissances sur le sujet des chaînes de Markov ainsi que de leurs applications. Je tiens à remercier chaleureusement Monsieur KAZI-TANI, enseignant-chercheur au sein de l'IECL, pour m'avoir accompagné tout au long de ce stage. Sa disponibilité, ses conseils et son expertise m'ont permis d'enrichir significativement mes connaissances mathématiques, d'appréhender au mieux la lecture et la rédaction de documents, et m'ont permis de découvrir une facette du métier de chercheur que je n'aurais pas imaginée.

Ce rapport, qui est la finalité d'un stage qui aura duré cinq mois, est une synthèse de tous les ouvrages que j'ai pu étudier, et inclut également une simulation du modèle d'Ising. Le rapport traitera plus généralement de l'essence des chaînes de Markov, pour introduire à la simulation du modèle d'Ising à l'aide des méthodes de Monte Carlo par Chaînes de Markov.

1 Chaines de Markov

1.1 Définition et premières propriétés

Les chaînes de Markov sont un outil incontournable en probabilités, puisqu'elles permettent de modéliser efficacement un grand nombre de phénomènes aléatoires en temps discret. Introduites au début du XXème siècle par le mathématicien russe Andreï Markov, ces processus stochastiques en temps discret possèdent une propriété essentielle : en un temps n , l'évolution d'un système au temps futur $(n + 1)$ ne dépend uniquement de l'état du système au temps présent, et non pas des états passés.

Définition 1.1.1 (Chaine de Markov). Soient $(E, \mathcal{A}, \mathbb{P})$ un espace probabilisé, et $(X_n)_{n \in \mathbb{N}}$ une suite de variables aléatoires. On dit que la suite $(X_n)_{n \in \mathbb{N}}$ est une Chaine de Markov si pour tout $n \in \mathbb{N}$:

$$\mathbb{P}(X_{n+1} = x_{n+1} \mid X_n = x_n, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) = \mathbb{P}(X_{n+1} = x_{n+1} \mid X_n = x_n)$$

E sera aussi appelé espace d'états. On appellera loi initiale de la chaîne la mesure de probabilité $\mu = \mathbb{P}(X_0 = \cdot)$

Définition 1.1.2 (Noyau de transition d'une chaîne de Markov). Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov définie sur un espace d'états E supposé fini ou dénombrable. On appelle noyau de transition de la chaîne de Markov $(X_n)_{n \in \mathbb{N}}$ la matrice Q définie par :

$$Q^{(n)} = (q_{i,j}) \quad \text{avec} \quad q_{i,j} = \mathbb{P}(X_{n+1} = j \mid X_n = i)$$

Remarque. Un noyau de Markov est une matrice stochastique. Par conséquent, chaque ligne du noyau de Markov est une loi de probabilité discrète.

Proposition 1.1.3. Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov de noyau de transition Q , définie sur un espace d'états E supposé fini ou dénombrable, et soit μ la mesure initiale de la chaîne. Alors, pour tout $x_0, \dots, x_n \in E$, on a :

$$\mathbb{P}(X_0 = x_0 \cap \dots \cap X_n = x_n) = \mu(x_0)Q(x_0, x_1) \dots Q(x_{n-1}, x_n)$$

Proposition 1.1.4 (Invariance par translation temporelle). Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov de noyau de transition Q , définie sur un espace d'états E supposé fini ou dénombrable. Soient $k, n \in \mathbb{N}$, $x_0, \dots, x_{n+k} \in E$ tels que $\mathbb{P}(X_0 = x_0 \cap \dots \cap X_k = x_k) > 0$. Alors on a :

$$\begin{aligned} & \mathbb{P}(X_{n+k} = x_{n+k} \cap \dots \cap X_{k+1} = x_{k+1} \mid X_k = x_k \cap \dots \cap X_0 = x_0) \\ &= \mathbb{P}(X_n = x_{n+k} \cap \dots \cap X_1 = x_{k+1} \mid X_0 = x_k) \\ &= Q(x_k, x_{k+1}) \times \dots \times Q(x_{n+k-1}, x_{n+k}) \end{aligned}$$

Démonstration. Soient $k, n \in \mathbb{N}$, $x_0, \dots, x_{n+k} \in E$ tels que $\mathbb{P}(X_0 = x_0 \cap \dots \cap X_k = x_k) > 0$. Soit μ la mesure initiale de la chaîne. On a :

$$\begin{aligned} & \mathbb{P}(X_{n+k} = x_{n+k} \cap \dots \cap X_{k+1} = x_{k+1} \mid X_k = x_k \cap \dots \cap X_0 = x_0) \\ &= \frac{\mathbb{P}(X_{n+k} = x_{n+k} \cap \dots \cap X_0 = x_0)}{\mathbb{P}(X_n = x_n \cap \dots \cap X_0 = x_0)} \end{aligned}$$

$$\begin{aligned}
& \mu(x_0) \prod_{i=0}^{n+m-1} Q(x_i, x_{i+1}) \\
= & \frac{\mu(x_0) \prod_{i=0}^{n-1} Q(x_i, x_{i+1})}{\mu(x_0) \prod_{i=0}^{n-1} Q(x_i, x_{i+1})} \\
= & \prod_{i=n}^{n+k-1} Q(x_i, x_{i+1}) \\
= & \frac{\mathbb{P}(X_n = x_{n+k} \cap \dots \cap X_0 = x_k)}{\mathbb{P}(X_0 = x_k)} \\
= & \mathbb{P}(X_n = x_{n+k} \cap \dots \cap X_1 = x_{k+1} \mid X_0 = x_n)
\end{aligned}$$

D'où le résultat. $\square$

Proposition 1.1.5. Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov de noyau de transition Q , définie sur un espace d'états E supposé fini ou dénombrable. Alors, pour tout $k, n \in \mathbb{N}$, $x_0, x_1, \dots, x_{n+k} \in E$, on a :

$$\begin{aligned}
& \mathbb{P}(X_{n+k} = x_{n+k} \cap \dots \cap X_{k+1} = x_{k+1} \mid X_k = x_k \cap \dots \cap X_0 = x_0) \\
= & \mathbb{P}(X_n = x_{n+k} \cap \dots \cap X_1 = x_{k+1} \mid X_0 = x_k) \\
= & Q(x_k, x_{k+1}) \times \dots \times Q(x_{n+k-1}, x_{n+k})
\end{aligned}$$

Proposition 1.1.6. Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov de noyau de transition Q , définie sur un espace d'états E supposé fini ou dénombrable. Alors, pour tout $k, n \in \mathbb{N}$, $x, y \in E$, on a

$$\mathbb{P}(X_{n+k} = y \mid X_k = x) = Q^{(n)}(x, y) = Q^n(x, y)$$

Démonstration. Soient $k, n \in \mathbb{N}$, $x, y \in E$. On a :

$$\begin{aligned}
\mathbb{P}(X_{n+k} = y \mid X_k = x) &= \sum_{x_{k+1}, \dots, x_{n+k-1} \in E} \mathbb{P}(X_{n+k} = y \mid X_{n+k-1} = x_{n+k-1} \cap \dots \cap X_{k+1} = x_{k+1} \mid X_k = x) \\
&= \sum_{x_{k+1}, \dots, x_{n+k-1} \in E} Q(x, x_{k+1}) \times Q(x_{k+1}, x_{k+2}) \times \dots \times Q(x_{n+k-1}, y) \\
&= Q^n(x, y)
\end{aligned}$$

D'où le résultat. $\square$

Theorème 1.1 (Équations de Chapman-Kolmogorov). Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov de noyau de transition Q , définie sur un espace d'états E . Soient $n, m \in \mathbb{N}$. Alors on a :

$$Q^{(n+m)} = Q^{(n)} \times Q^{(m)}$$

et l'équation suivante est vérifiée :

$$\forall (x, y) \in E^2, \mathbb{P}(X_{n+m} = y \mid X_0 = x) = \sum_{z \in E} \mathbb{P}(X_n = z \mid X_0 = x) \mathbb{P}(X_m = y \mid X_0 = z)$$

Démonstration. Les deux égalités découlent des propositions 1.1.5 et 1.1.6, ainsi que du produit matriciel. $\square$

1.2 Classification des états

Avec de telles notions introduites, on aimerait pouvoir classer les états qu'une chaîne de Markov peut prendre.

Définition 1.2.1. Soit $(E, \mathcal{A}, \mathbb{P})$ un espace d'état et $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov sur E . Soient x et y deux états de E .

- On dit que x est accessible depuis y si

$$(\exists n \in \mathbb{N}), \mathbb{P}(X_n = y \mid X_0 = x) > 0$$

Autrement dit, en partant de l'état x , il existe un temps à partir duquel l'état y est atteint avec une probabilité non nulle. Dans ce cas, on notera $x \rightarrow y$.

- On dit que x et y communiquent si $x \rightarrow y$ et $y \rightarrow x$. Dans ce cas, on notera $x \leftrightarrow y$.

Remarque. La notion de communication entre deux états x et y est une relation d'équivalence sur E . En effet, on a, pour $x, y, z \in E$:

- **Réflexivité** : $\mathbb{P}(X_0 = x \mid X_0 = x) = 1 > 0$, donc $x \rightarrow x$ ce qui signifie que $x \leftrightarrow x$.
- **Symétrie** : Trivial, par la définition.
- **Transitivité** : Supposons que $x \leftrightarrow y$ et $y \leftrightarrow z$. Alors il existe $n, m \in \mathbb{N} : \mathbb{P}(X_n = y \mid X_0 = x) > 0$ et $\mathbb{P}(X_m = z \mid X_0 = y) > 0$. On a :

$$\begin{aligned} \mathbb{P}(X_{n+m} = z \mid X_0 = x) &= \sum_{y' \in E} \mathbb{P}(X_m = z \mid X_n = y') \mathbb{P}(X_n = y' \mid X_0 = x) \\ &\geq \mathbb{P}(X_m = z \mid X_n = y) \mathbb{P}(X_n = y \mid X_0 = x) \\ &> 0 \end{aligned}$$

D'où $x \rightarrow z$. On peut montrer de même que $z \rightarrow x$ et donc on peut en déduire que $x \leftrightarrow z$.

Ainsi, comme la relation de communication est une relation d'équivalence, on peut partitionner E en classes d'équivalence :

Définition 1.2.2 (Classe de communication). Soit $(E, \mathcal{A}, \mathbb{P})$ un espace d'état et $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov sur E . Soit $x \in E$. On appelle classe de communication de x , et on note C_x , l'ensemble des $y \in E$ tels que x et y communiquent.

$$C_x = \{y \in E \mid x \leftrightarrow y\}$$

Définition 1.2.3. Soit $(E, \mathcal{A}, \mathbb{P})$ un espace d'état et $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov sur E . On dit que $(X_n)_{n \in \mathbb{N}}$ est irréductible si tous les états communiquent deux-à-deux. Ainsi, E n'admet qu'une seule classe de communication.

1.3 Théorème ergodique et convergence ergodique

Nous avons vu que chaque ligne d'un noyau de transition représente une loi de probabilité. Nous aimerions savoir si, pour un noyau de Markov Q donné, chaque ligne de $Q^{(n)}$ converge vers une certaine loi lorsque n tend vers l'infini. Le théorème suivant nous donne des conditions sur une telle convergence :

Théorème 1.2 (Théorème de convergence ergodique pour les chaînes de Markov). *Soit $(E, \mathcal{A}, \mathbb{P})$ un espace d'état fini et $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov sur E de noyau de transition Q . Alors il existe une unique mesure de probabilité π telle que :*

- π est Q -invariante (i.e. $\pi Q = \pi$)
- Pour toute loi initiale μ et fonction f μ -intégrable, on a :

$$\frac{1}{n} \sum_{k=1}^n f(X_k) \xrightarrow[n \rightarrow +\infty]{p.s.} \int_E f(X_k) d\mu$$

Ce théorème nous assure l'existence et l'unicité, sous la condition d'irréductibilité de la chaîne de Markov considérée, d'une mesure de probabilité invariante (ou stationnaire). Le résultat suivant nous propose une estimation de la vitesse de convergence d'une chaîne de Markov vers sa loi stationnaire, mais sous certaines contraintes plus restrictives.

Théorème 1.3 (Vitesse de convergence vers la loi stationnaire). *Soit $(E, \mathcal{A}, \mathbb{P})$ un espace d'état fini et $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov irréductible, apériodique sur E , de noyau de transition Q et admettant une loi Q -invariante π . Alors, il existe $M > 0$ et $\alpha \in [0, 1[$ tels que, pour tout $x, y \in E$,*

$$|Q^{(n)}(x, y) - \pi(y)| \leq M\alpha^n$$

2 Méthodes de Monte Carlo par Chaînes de Markov

En probabilités appliquées, les méthodes de Monte Carlo sont une catégorie d'algorithmes permettant, à partir d'une série de processus stochastiques, d'approximer des valeurs numériques. Ces méthodes sont très utilisées dans le cadre d'estimation de valeurs d'intégrales en dimension quelconque, mais trouvent des applications dans un grand nombre de domaines appliqués (finance, physique, informatique, ...).

Dans cette section, nous traiterons une sous-famille des algorithmes de Monte-Carlo : les Méthodes de Monte-Carlo par chaînes de Markov (ou MCMC pour *Monte Carlo Markov Chains*). Nous avons détaillé dans la section précédente des conditions pour lesquelles une chaîne de Markov admet une probabilité stationnaire. Cependant, une telle loi peut être très fastidieuse, voire impossible à expliciter ou à calculer. En effet, plusieurs problèmes peuvent nous empêcher de calculer explicitement des résultats :

- La distribution ne suit pas nécessairement une loi connue ou identifiable par des procédés généraux.
- On sait expliciter la distribution mais le calcul d'une probabilité demande de faire des millions de calculs (ou plus). Cela peut être dû à la constante de normalisation, qui peut être très fastidieuse à calculer.

C'est alors que l'on peut introduire les MCMC. De tels algorithmes permettent, pour une chaîne de Markov donnée $(X_n)_{n \in \mathbb{N}}$ d'approximer une loi π . Généralement, si $(X_n)_{n \in \mathbb{N}}$ admet une loi stationnaire, c'est cette loi qu'on cherchera à approximer. Les MCMC permettent aussi de construire une chaîne de Markov dont la loi stationnaire approche π , uniquement à partir d'échantillons. Simuler cette chaîne de Markov artificiellement construite nous permet alors d'approcher la loi π .

L'idée est, à partir d'un échantillon X_i généré selon la loi π que l'on souhaite simuler, de générer un échantillon suivant X_{i+1} dépendant uniquement de la valeur prise par X_i . Ainsi, en prenant différents échantillons X_0 et en appliquant un tel processus, on génère une liste de suites $(X_n)_{n \in \mathbb{N}}$, qui sont en réalité des chaînes de Markov (par construction), et qui convergent vers la loi π . L'objectif est d'ensuite simuler suffisamment longtemps une telle chaîne de Markov pour engendrer la loi π .

Dans la suite de ce rapport, nous utiliserons un algorithme de Monte-Carlo par chaîne de Markov particulier : l'algorithme de Metropolis-Hastings. L'intérêt de cet algorithme est de simuler une loi de probabilité π , que l'on connaît à un facteur multiplicatif près. Théoriquement, pour pouvoir exploiter une telle mesure, on se devrait de connaître la mesure de l'ensemble total pour pouvoir ensuite normaliser la mesure connue et arriver à une loi de probabilité. En pratique, calculer cette constante de normalisation peut nécessiter de longs calculs que même un ordinateur puissant mettrait du temps à aboutir.

Définition 2.0.1 (Algorithme de Metropolis-Hastings). *Soient f une fonction proportionnelle à une loi π que l'on souhaite simuler, et $(E, \mathcal{A}, \mathbb{P})$ un espace d'états probabilisé. Soit P un noyau de Markov. Le but est de construire une chaîne de Markov $(X_n)_{n \in \mathbb{N}}$ convergeant vers la loi π .*

- **Initialisation** : on choisit un $x_0 \in E$ tel que $f(x_0) > 0$. Dans ce cas, on pose $X_0 = x_0$

- **Construction récurrente** : Soit $n \in \mathbb{N}$. On suppose que $X_n = x$. On simule alors deux variables aléatoires $Y_{n+1} \sim P(x, \cdot)$ et $U_{n+1} \sim \mathcal{U}([0, 1])$ indépendantes des précédentes simulations. On pose, pour tout $x, y \in E$:

$$\rho(x, y) = \min \left(1, \frac{f(y)P(y, x)}{f(x)Q(x, y)} \right)$$

et on pose

$$X_{n+1} = \begin{cases} Y_{n+1} & \text{si } U_{n+1} \leq \rho(X_n, Y_{n+1}) \\ X_n & \text{sinon.} \end{cases}$$

3 Temps de mélange et phénomène de Cutoff

On se fixe dans cette section un espace probabilisé fini $(E, \mathcal{A}, \mathbb{P})$. Considérons $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov sur l'espace d'état E . On sait que sous certaines conditions, $(X_n)_{n \in \mathbb{N}}$ converge vers une loi de probabilité stationnaire π . La question est de savoir à quelle vitesse cette convergence a lieu, et à quel point celle-ci dépend de la taille de l'espace des états. Pour mesurer l'écart entre la loi de $P(x, \cdot)$ et la loi stationnaire π , nous devons introduire une distance sur l'ensemble des mesures de probabilités sur E . Intuitivement, on peut définir la distance entre deux mesures μ et ν sur E par :

$$d_E(\mu, \nu) = \max_{A \subseteq E} |\mu(A) - \nu(A)|$$

Ainsi, en fixant $\nu = \pi$, on peut quantifier l'écart entre la loi $P(x, \cdot)$ et la loi stationnaire π . On introduit alors la *distance en variation totale*.

Définition 3.0.1 (Distance en Variation Totale). Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov de noyau de transition P et admettant une mesure stationnaire π . On définit la variation totale $\mathcal{D}$ comme étant la fonction définie par

$$\begin{aligned} \mathcal{D} : \mathbb{N} &\rightarrow [0, 1] \\ n &\mapsto \left\| P^{(n)} - \pi \right\|_{VT} = \max_{x \in E} |P^{(n)}(x, \cdot) - \pi| \end{aligned}$$

Maintenant, on aimerait définir le rang $n \in \mathbb{N}$ à partir duquel, pour un $\varepsilon > 0$ donné, les lois du noyau sont ε -proches de la loi stationnaire π . Ainsi on peut introduire :

Définition 3.0.2 (Temps de mélange). Soient $(P_n)_{n \in \mathbb{N}}$ une suite de noyaux de Markov et $(\mathcal{D}_n)_{n \in \mathbb{N}}$ leur fonction de distance en variation totale associée. Le temps de mélange de $(P_n)_{n \in \mathbb{N}}$ est défini par :

$$t_{mix}^{(n)}(\varepsilon) = \inf \{ m \in \mathbb{N} \mid \mathcal{D}_n(m) < \varepsilon \}$$

Ainsi, en considérant une chaîne de Markov de noyau P et la suite de noyaux définie par $P_n = P^{(n)}$, le temps de mélange de la chaîne de Markov correspond à l'instant où toutes les lois $P(x, \cdot)$ sont ε -proches de π , pour tout $x \in E$. Seulement, dans certaines configurations de chaînes de Markov, on peut observer un phénomène particulier : le temps de mélange ne dépend pas, ou très peu, de la valeur ε arbitrairement choisie. On introduit alors la notion de *cutoff*.

Définition 3.0.3 (Phénomène de Cutoff). Soient $(P_n)_{n \in \mathbb{N}}$ une suite de noyaux de Markov et $(\mathcal{D}_n)_{n \in \mathbb{N}}$ leur fonction de distance en variation totale associée. On dit que la suite $(P_n)_{n \in \mathbb{N}}$ admet un temps de Cutoff si :

$$\forall \varepsilon \in]0, 1[, \lim_{n \rightarrow +\infty} \frac{t_{mix}(\varepsilon)}{t_{mix}(1 - \varepsilon)} = 1$$

ce qui signifie que la distance à la mesure stationnaire reste proche de 1 pendant un temps déterminé, mais que cette dernière chute rapidement vers 0 à partir d'un certain temps.

4 Application : Le modèle d'Ising

4.1 Ferromagnétisme d'un matériau

On dit d'un matériau qu'il est *ferromagnétique* lorsqu'il est susceptible de s'aimanter sous l'effet d'un champ magnétique extérieur, ou d'une action extérieure. Un tel matériau peut se décomposer, à l'échelle atomique, en plusieurs petites régions, de l'ordre de quelques dizaines de microns, appelées *domaines de Weiss*, dans lesquelles les moments magnétiques sont tous orientés dans une même direction. Les électrons dans ces régions ont ainsi tendance à avoir le même *spin*.

Le ferromagnétisme d'un matériau dépend également de sa température : en effet, plus cette dernière est basse, plus le matériau possède des propriétés magnétiques, c'est-à-dire que les électrons de même spin vont s'agglutiner en gros blocs. Au contraire, plus le matériau possède une température élevée, alors plus celui-ci va perdre son magnétisme, et par extension, plus les électrons de même spin vont se séparer. On appelle ce phénomène le *paramagnétisme*. Ainsi, pour un matériau ferromagnétique, on peut conjecturer l'existence d'une température T , telle qu'en deçà de celle-ci, le matériau reste magnétique, et qu'au-dessus de celle-ci, le matériau ne l'est plus. En 1857, le physicien *Pierre Curie* démontre qu'une telle température existe, et cette dernière sera nommée *Température de Curie* ou *Point de Curie*.




FIGURE 1 – Représentation du phénomène de transition ferromagnétisme - paramagnétisme dans un matériau, avec représentation de la température de Curie

4.2 Modèle d'Ising : quelques généralités

Le modèle d'Ising est un modèle probabiliste permettant de modéliser le phénomène de *ferromagnétisme* d'un matériau. Étant donné que l'électron est une particule de *spin* $\frac{1}{2}$, cette dernière ne peut prendre que deux orientations : $+\frac{1}{2}$ et $-\frac{1}{2}$. Par souci de simplicité, nous identifierons les spins d'un électron par $+1$ et -1 . Plutôt que d'étudier un nombre très élevé de directions de moments magnétiques, on se restreindra à étudier les spins d'électrons : en effet, les moments magnétiques des électrons peuvent être associés à leur spin. Ainsi, plutôt que d'étudier les moments magnétiques en soi, on peut étudier les spins de leurs électrons.

associés.

Introduisons un ensemble fini $E \subset \mathbb{Z}^n$ supposé contenir un ensemble d'électrons e .

Définition 4.2.1 (Configuration de spin). *On appelle configuration de spin une application $\sigma : E \rightarrow \{-1, 1\}$, qui à tout électron de E associe un spin quelconque. On notera $\mathcal{C}_E$ l'ensemble des configurations de spin de l'ensemble E .*

Définition 4.2.2. *On dit que deux électrons $e_1 = (x_1, x_2, \dots, x_n)$ et $e_2 = (x'_1, x'_2, \dots, x'_n)$ de E sont voisins, et on notera $e_1 \sim e_2$, si leurs coordonnées vérifient*

$$\sum_{k=1}^n |x_k - x'_k| = 1$$

Définition 4.2.3 (Loi d'Ising, modèle d'Ising). *Soient $\alpha, \beta \in \mathbb{R}$. On appelle Loi d'Ising sur le matériau E la loi de probabilité sur $\mathcal{C}_E$ définie par :*

$$\mathbb{P}_{\alpha, \beta}(\sigma) = \frac{1}{Z_E(\alpha, \beta)} \exp \left(\alpha \sum_{e \in E} \sigma(e) + \beta \sum_{e \sim e' \in E} \sigma(e) \sigma(e') \right)$$

où $\frac{1}{Z_E(\alpha, \beta)}$ est la constante de normalisation de $\mathbb{P}_{\alpha, \beta}$, qui la fait passer d'une mesure à une mesure de probabilité. On appellera modèle d'Ising une configuration de spins suivant la loi d'Ising.

Le modèle d'Ising ne sert pas uniquement à simuler le ferromagnétisme d'un matériau, mais tout phénomène qui repose sur des interactions de particules voisines. Dans le cas d'une étude thermodynamique sur le ferromagnétisme d'un matériau, il est courant de fixer le paramètre $\alpha = 0$, qui n'a pas de réel intérêt dans ce cas. Ainsi, le paramètre β représentera environ l'inverse de la température : $\beta \approx \frac{1}{T}$.

4.3 Modèle d'Ising en deux dimensions : étude et simulations

4.3.1 Construction théorique

On se fixe une partie finie $E \subset \mathbb{Z}^2$. Par souci de simplicité, on considérera E comme un carré de taille n , que l'on pourra facilement identifier à une matrice de même taille. Ainsi :

- Pour tout électron $e_{x,y} = (x, y)$ de E , on aura $x, y \in \llbracket 1; n \rrbracket$.
- Une configuration σ sur l'espace E peut être représentée par la matrice $C_\sigma = (c_{i,j})_{1 \leq i, j \leq n}$ où $c_{i,j} = \sigma(e_{i,j}) = \sigma(i, j)$, $\forall i, j \in \llbracket 1; n \rrbracket$.

Un exemple de configuration de taille 5×5 peut être :

$$\begin{bmatrix} 1 & 1 & -1 & 1 & 1 \\ -1 & -1 & 1 & 1 & -1 \\ 1 & -1 & -1 & -1 & -1 \\ 1 & 1 & 1 & -1 & -1 \\ -1 & 1 & -1 & 1 & -1 \end{bmatrix}$$

L'intérêt de cette section est de simuler le modèle d'Ising à partir des Méthodes de Monte Carlo par Chaines de Markov. L'idée est de partir d'une configuration de spin aléatoire σ , et d'opérer des modifications probabilistes sur σ pour obtenir, après un certain nombre de récursions, une approximation du modèle d'Ising pour la configuration σ .

Soit σ une configuration aléatoire dans $\mathcal{C}_E$. On définit, pour $e = (x, y) \in E$:

- $V_\sigma^+(e) = \text{Card}(\{e' \sim e ; \sigma(e') = 1\})$
- $V_\sigma^-(e) = \text{Card}(\{e' \sim e ; \sigma(e') = -1\})$

On va construire une chaîne de Markov convergeant vers la loi d'Ising à l'aide de l'algorithme de *Metropolis-Hastings*. Soit $(\sigma_n)_{n \in \mathbb{N}}$ une suite de configurations de spins de E telle que $\sigma_0 = \sigma$.

- **Étape 1 :**
On choisit aléatoirement un électron $e = (x, y)$ dans E .
- **Étape 2 :**
On tire aléatoirement et uniformément u dans $[0, 1]$.
- **Étape 3 :**
On définit la configuration σ_{new} définie par

$$[\forall (i, j) \in \llbracket 1; n \rrbracket^2 \setminus \{e\}], \quad \sigma_{new}(i, j) = \sigma(i, j)$$

et


- $\sigma_{new}(e) = 1$ si $u < \frac{e^{\alpha + \beta(V_\sigma^+(e) - V_\sigma^-(e))}}{2 \cosh(\alpha + \beta(V_\sigma^+(e) - V_\sigma^-(e)))}$
 - $\sigma_{new}(e) = -1$ sinon
- Et on note $\sigma_{new} = MH_{e,u}(\sigma)$

En initialisant $(e_n)_{n \in \mathbb{N}}$ une suite de variables aléatoires indépendantes suivant une loi uniforme sur E , $(u_n)_{n \in \mathbb{N}}$ une suite de variables aléatoires indépendantes suivant une loi uniforme sur $[0, 1]$, et en posant $\sigma_{n+1} = MH_{e_n, u_n}(\sigma_n)$, on obtient une Chaîne de Markov irréductible, récurrente et apériodique qui converge vers une unique mesure de probabilité, qui est la loi d'Ising.


Ainsi, en prenant une valeur de n assez grande, la loi de la configuration σ_n est proche de la Loi d'Ising.

4.3.2 Quelques exemples tirés de la simulation


Simulation pour $\alpha = 0, \beta = 0.05$:



$n = 30$, 2000 itérations




$n = 100$, 500.000 itérations




$n = 300$, 1.000.000 itérations


Simulation pour $\alpha = 0, \beta = 0.45$:



$n = 30$, 2000 itérations



$n = 100$, 500.000 itérations




$n = 300$, 1.000.000 itérations


Simulation pour $\alpha = 0, \beta = 0.55$:



$n = 30$, 2000 itérations




$n = 100$, 500.000 itérations



$n = 300$, 1.000.000 itérations


Simulation pour $\alpha = 0, \beta = 0.95$:



$n = 30$, 2000 itérations



$n = 100$, 500.000 itérations



$n = 300$, 1.000.000 itérations

On constate que, plus β augmente (c'est-à-dire plus la température du matériau diminue), plus les domaines de Weiss deviennent perceptibles et compacts. De plus, on remarque un changement assez brut pour $\beta \in [0.45, 0.55]$. On conjecture alors que, pour une configuration aléatoire, il existe une *température de Curie* T_C , telle que $\beta_C \in [0.45, 0.55]$, avec $\beta_C \approx \frac{1}{T_C}$.

4.4 Phénomène de Cutoff pour le modèle d'Ising

Pour les résultats obtenus précédemment, le nombre de récursions a été fixé arbitrairement, de telle sorte à ce que le résultat de l'algorithme donne une approximation visuellement cohérente. Nous pouvons alors nous demander si la chaîne de Markov permettant de converger vers le modèle d'Ising admet un temps de Cutoff, et si oui, de quel ordre est-il. Le premier résultat introduit une estimation du temps de mélange pour le modèle d'Ising.

Proposition 4.4.1. *Considérons $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov convergeant vers le modèle d'Ising de paramètre β et de taille $n \times n$. Si $4 \tanh(\beta) < 1$, alors :*

$$t_{mix}(\varepsilon) \leq \left\lfloor \frac{n^2(2 \ln(n) + \ln(\frac{1}{\varepsilon}))}{1 - 4 \tanh(\beta)} \right\rfloor + 1$$

D'après les travaux de *Eyal Lubetzky* et *Allan Sly*, le temps de cutoff pour la chaîne de Markov construite précédemment à l'aide de Metropolis-Hastings est, pour un plateau de taille $N \times N$ et de température de Curie T_C associé au β critique β_C :

- de l'ordre de $O(N^2 \ln(N))$ si $T > T_C$ (i.e. $\beta < \beta_C$) ;
- de l'ordre de $O(e^N)$ si $T < T_C$ (i.e. $\beta > \beta_C$) ;
- n'est pas vraiment défini pour $T \approx T_C$ (i.e. $\beta \approx \beta_C$).

Cependant, même si cette proposition fournit une estimation raisonnable du temps de cutoff pour le modèle d'Ising, elle est malheureusement, en pratique, peu applicable. En effet, cette estimation ne s'applique que pour des températures très élevées, telles que $\beta \leq \frac{1}{4}$ environ, pour que l'on puisse avoir $4 \tanh(\beta) < 1$. Pour des cas plus généraux, il convient d'introduire une autre estimation du temps de cutoff, démontrée par D.A. Levin, M.J. Luczak, Y. Peres.

Proposition 4.4.2. *Soient $(E, \mathcal{A}, \mathbb{P})$ un espace probabilisé, $\sigma \in \mathcal{C}_E$ et $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov telle que $X_0 = C_\sigma$ et construite via l'algorithme de Metropolis-Hastings pour le modèle d'Ising de paramètre β sur un plateau de taille $m \times m$. Si $\beta < 1$, alors $(X_n)_{n \in \mathbb{N}}$ admet un temps de cutoff en $t_{\text{cutoff}} = \lfloor \frac{1}{(1-\beta)} m^2 \ln(m) \rfloor + 1$.*

Appendices

A Simulation du modèle d'Ising en Python

```
1      import math
2      import random
3      from math import *
4      from random import *
5      import numpy as np
6      import numpy.random as npr
7      import matplotlib.pyplot as plt
8
9      def espace(n):
10         return np.ones((n,n))
11
12      def voisins(e1,e2):
13         """
14         Cette fonction permet de, etant donne deux electrons e1, e2 sous
15         forme de coordonees, dire s'ils sont voisins
16         """
17         sum = 0
18         if len(e1) != len(e2): #0n verifie bien que les electrons sont
19         donnees sous la meme forme.
20             return False
21         for i in range(len(e1)):
22             sum = sum + abs(e1[i]-e2[i])
23         if sum == 1:
24             return True
25         else:
26             return False
27
28      def rademacher(p):
29         """
30         Cette fonction permet de simuler une loi de Rademacher :  $P_X = p \cdot$ 
31          $\delta(-1) + (1-p) \cdot \delta(1)$ 
32         """
33         u=npr.random()
34         if p>u:
35             return 1
36         else:
37             return -1
38
39      def configuration(n):
40         """
41         Cette fonction permet de generer une configuration initiale
42         al atoire de taille n*n, selon la loi de Rademacher, c'est-a-dire une
43         grille d'electrons de spin -1 ou 1, repartis selon la loi de Rademacher.
44         """
45         E = espace(n)
46         for i in range(0,n):
47             for j in range(0,n):
48                 E[i,j] = rademacher(1/2)
49         return E
50
51      def plot_config(E):
52         """
53         Cette fonction configure l'affichage graphique des resultats.
54         """
55         n = len(E)
```

```

52     fig, ax = plt.subplots()
53
54     for i in range(n):
55         for j in range(n):
56             couleur = 'black' if E[i][j] == 1 else 'white'
57             ax.add_patch(plt.Rectangle((j, n - i - 1), 1, 1, color=
couleur))
58     ax.set_xlim(0, n)
59     ax.set_ylim(0, n)
60     ax.set_xticks(range(n + 1))
61     ax.set_yticks(range(n + 1))
62     ax.set_aspect('equal')
63     ax.grid(True, which='both', linewidth=0)
64     ax.tick_params(left=False, bottom=False, labelleft=False,
labelbottom=False)
65
66     plt.show()
67
68     def P(e,config):
69         """
70         Cette fonction renvoie le nombre d'electrons de spin positif
voisins d'un electron e donne dans une configuration config donnee.
71         """
72         x, y = e
73         n = config.shape[0]
74         voisins = [(x - 1, y), (x + 1, y), (x, y - 1), (x, y + 1)]
75         return sum(config[i, j] == 1 for i, j in voisins if 0 <= i < n and
0 <= j < n)
76
77     def N(e,config):
78         """
79         Cette fonction renvoie le nombre d'electrons de spin negatif
voisins d'un electron e donne dans une configuration config donnee.
80         """
81         x, y = e
82         n = config.shape[0]
83         voisins = [(x - 1, y), (x + 1, y), (x, y - 1), (x, y + 1)]
84         return sum(config[i, j] == -1 for i, j in voisins if 0 <= i < n
and 0 <= j < n)
85
86     def u():
87         """
88         Cette fonction genere un reel de l'intervalle [0,1] de maniere
uniforme.
89         """
90         return npr.random()
91
92     def F(e,u,config):
93         """
94         Cette fonction effectue une iteration de l'algorithme de
Metropolis-Hastings.
95         """
96         new_config = config
97         seuil = math.exp(a+b*(P(e,config)-N(e,config)))/(2*math.cosh(a+b*(
P(e,config)-N(e,config))))
98         if u < seuil:
99             new_config[e] = 1
100         else:
101             new_config[e] = -1
102         return new_config
103
104     def simulation_ising(n,iterations):

```

```

105         """
106         Cette procedure permet de simuler le modele d'Ising sur une
107         configuration de taille n*n en un nombre deterministe d'iterations.
108         """
109         config_init = configuration(n) #On g n re une configuration
110         initiale al atoire
111         new_config = config_init
112         for k in range(0,iterations):
113             e_k = npr.randint(0,n,(1,2)) #On s lectionne de maniere
114             uniforme dans la configuration un electron
115             u_k = u()
116             new_config = F((e_k[0][0],e_k[0][1]),u_k,new_config) #On
117             applique l'algorithme sur l'electron aleatoire selectionne.
118             plot_config(new_config)

```

Références

- [1] Béatrice De Tilière. Chaînes de Markov. *Univeristé Paris-Est-Creteil ESIPE*.
- [2] Sylvain Rubenthaler. Méthodes de Monte-Carlo (Cours et exercices). *Université de Nice Sophia Antipolis*, 2018-2019.
- [3] Sebastien Gadat. Stabilité des dynamiques markoviennes et comportement en temps long. Algorithmes stochastiques. *Institut Mathematiques de Toulouse - Universite Paul Sabatier*, 2014.
- [4] Jian Ding, Eyal Lubetzky, and Yuval Peres. The Mixing Time Evolution of Glauber Dynamics for the Mean-Field Ising Model. *Communications in Mathematical Physics*, 2009.
- [5] Adam Zweiger. MCMC and the Ising Model.
- [6] David A. Levin. Cutoff for Markov Chains. *LMS-EPSRC Durham Symposium*, 2017.